

# 论文

September 7, 2023

## 1 介绍

交通运输电气化是实现碳排放减少和可持续发展的关键解决方案。电动汽车的推广将引领绿色智能交通系统在物流和能源领域的发展。在本文中，所提及的电动汽车均指纯电动汽车，其使用电能而几乎不产生污染物排放，因此是一种生态友好型的车辆。因此，电动汽车提供了一种清洁交通系统的选择，并具有巨大的可持续交通发展潜力。此外，电动汽车更容易与智能交通系统融合，从而增强了智能交通服务的效能。电动汽车可以通过智能充电设施进行充电，并与智能手机等设备连接，实现远程监控和管理，为充电提供智能化解决方案。同时，电动汽车还可以与其他交通工具和基础设施进行信息共享和协同，以实现交通系统的整体优化和智能化调度。通过与智能交通系统的结合，电动汽车可以参与智能导航、实时路况监测和拥堵缓解等功能，提高交通系统的效率和可持续性。因此，电动汽车在推动绿色智能交通系统的发展方面扮演着重要的角色，并为未来交通运输的可持续发展提供了新的可能性。

### 1.1 文献综述

## 2 问题描述

本研究旨在开发一种能够实现分布式电网削峰提谷的协调方法。在电动汽车充电调度过程中，电动汽车聚合器负责收集充电信息并进行调度。当电动汽车接入电网后，车主会设置充电相关信息并发送给电动汽车聚合器。这些信息包括电动汽车连接到微电网时的到达时间和离开时间，以及电池的充电状态（SOC）。同时还包括充电需求的最低SOC和电池安全的最高SOC。在该模型中，电动汽车用户在将电动汽车接入充电桩时，会向聚合器上传充电需求信息。然后聚合器会向每辆电动汽车用户发送充电计划。充电需求信息中包括到达时间

（tic）和出发时间（tid）等信息。电动汽车到达时间 $t_c$ 和出发时间 $t_d$ 服从正态分布，可表示为：

$$f(t_c) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma_{t_c}} \exp\left(-\frac{(t_c+24-\mu_{t_c})^2}{2\sigma_{t_c}^2}\right), & 0 < t_c \leq \mu_{t_c} - 12; \\ \frac{1}{\sqrt{2\pi}\sigma_{t_c}} \exp\left(-\frac{(t_c-\mu_{t_c})^2}{2\sigma_{t_c}^2}\right), & \mu_{t_c} - 12 < t_c \leq 24; \end{cases} \quad (2.1)$$

$$f(t_{dis}) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma_{t_{dis}}} \exp\left(-\frac{(t_{dis}-\mu_{t_{dis}})^2}{2\sigma_{t_{dis}}^2}\right), & 0 < t_{dis} \leq \mu_{t_{dis}} + 12; \\ \frac{1}{\sqrt{2\pi}\sigma_{t_{dis}}} \exp\left(-\frac{(t_{dis}-24-\mu_{t_{dis}})^2}{2\sigma_{t_{dis}}^2}\right), & \mu_{t_{dis}} + 12 < t_{dis} \leq 24; \end{cases} \quad (2.2)$$

其中  $\mu_{t_c} = 18, \sigma_{t_c} = 3.3, \mu_{t_{dis}} = 8, \text{和} \sigma_{t_{dis}} = 3.24$

### 2.1 时间划分

在调度过程中，调度计划通常以时间段为单位执行，以提高执行效率。将调度时间划分为多个时间段。在提出的电动汽车充电调度模型中，将一天离散为96个时隙，每个时隙的长度为15min，则每辆电动汽车的到达时间和出发时间表示为：

$$J_i^c = \left\lceil \frac{t_i^c}{\Delta T} \right\rceil, i = 1, 2, \dots, N. \quad (2.3)$$

$$J_i^{dis} = \left\lceil \frac{t_i^{dis}}{\Delta T} \right\rceil, i = 1, 2, \dots, N. \quad (2.4)$$

其中N表示为EV数量， $i$ 为EV的指数， $i=1,2,\dots,N$ 。j是一天的时间指数，且 $j=1,\dots,96$ 。 $J_i^c$ 和 $J_i^{dis}$ 表示时隙的序号当电动汽车分别接入分布式电网和断开分布式电网。 $t_i^c$ 和 $t_i^{dis}$ 表示第 $i$ 辆电动汽车到达时间和出发时间， $\Delta T$ 表示时间步长。

## 3 充电调度模型

### 3.1.1 充电总成本

### 3.1 目标函数

在本节中建立一个协调调度充电模型来控制电动汽车充电，令  $\mathbf{p}_n \triangleq (p_{n,t}; t \in \mathcal{T}) \in \mathbb{R}^T, \mathbf{p} = (\mathbf{p}_1, \dots, \mathbf{p}_N)$ 。

它代表第 $n$ 辆电动汽车的充电总成本，其中， $E_t$ 为 $t$ 时间段的电价， $p_{n,t}$ 为电动汽车 $t$ 时间段的充电功率， $\Delta t$ 为时间间隔。

$$f_n(\mathbf{p}_n, \mathbf{t}) = \sum_{t \in \mathcal{T}} E_t p_{n,t} \Delta t \quad (3.1)$$

Table 1: 符号表示

$\mathcal{N}$	电动汽车个数集合: $\mathcal{N} = \{1, \dots, N\}$
$\mathcal{T}$	离散时间集合: $\mathcal{T} = \{1, \dots, T\}$
$\mathcal{L}$	馈线集合: $\mathcal{L} = \{1, \dots, L\}$
$p_{n,t}$	在 $t$ 时刻第 $n$ 辆电动汽车的充电速率
$\mathcal{N}_l$	通过馈线 $l$ 供电的电动汽车的集合
$\mathcal{N}_m$	在节点 $m$ 充电的电动汽车的集合
$C_n$	电动汽车的电池容量
$d_t$	在 $t$ 时刻总基本需求

### 3.1.2 满意度

$$g_n(\sum_{t \in \mathcal{T}} p_{nt}) = -(\sum_{t \in \mathcal{T}} p_{nt} - \Gamma_n)^2. \quad (3.2)$$

表示充电周期内的总能量的满意函数, 并且由 (3.2) 可知,  $EV n \in \mathcal{N}$  不随时间  $t \in \mathcal{T}$ , 电动汽车用户希望尽可能增加配电网提供的电量, 直到在期望周期内达到所需能量为止。

### 3.1.3 $\|p\|_0$

$\|p\|_0$  表示  $EV n$  用户的充电计划  $p_n$  的基数最小化, 在一定程度上考虑了EV用户的舒适度. 一方面, 用于尽量减少充电次数, 保护电池健康. 另一方面,  $EV$  用户希望尽可能地完成充电任务, 因为他们希望尽量减少中断或重新启动  $EV$  充电, 等待更长的时间来完成充电对大多数用户来说是不可接受的, 因此, 通过引入稀疏充电计划, 可以统一衡量用户满意度的目标

### 3.1.4 削峰填谷

$$h = (\sum_{n \in \mathcal{N}} (p_{n,t} + B_{n,t}) - \bar{p} + B)^2 \quad (3.3)$$

表示削峰填谷, 也表示配电网对总电力需求的功率损耗  $\sum_{n \in \mathcal{N}} p_{n,t} - \bar{p}$ ,  $\omega_n \in (0, \omega^{max})$  为权重参数, 反映了减少快速充电行为对电网不利影响的相对趋势. 且  $\bar{p} = (\sum_{t \in \mathcal{T}} \sum_{n \in \mathcal{N}} p_{n,t})/N$

根据以上各种指标介绍, 建立电动汽车用户的充电协调优化目标函数

$$\mathcal{J}_0(p) \triangleq \sum_{n \in \mathcal{N}} \left\{ f_n(p_{nt}) + g_n(\sum_{t \in \mathcal{T}} p_{nt}) + \|p_n\|_0 \right\} + \sum_{t \in \mathcal{T}} h_n(\sum_{t \in \mathcal{T}} p_{nt}) \quad (3.4)$$

## 3.2 约束

### 3.2.1 电动汽车充电策略约束

充电策略是影响电网投资的最重要因素, 为保证电网安全, 我们有如下不等式成立:

$$p_n^{min} \leq p_{n,t} \leq p_n^{max} \quad (3.5)$$

其中  $p_n^{min}$  和  $p_n^{max}$  分别是  $EV n$  的最大和最小充电功率

### 3.2.2 电网状态约束

通过决定电动汽车在每个时隙中是否充电, 实现了电动汽车的协调充电调度, 第  $n$  个  $EV$  充电状态如下:

$$x_{n,t} = \begin{cases} 1 & \text{如果电动汽车在充电,} \\ 0 & \text{其它.} \end{cases} \quad (3.6)$$

约束满足以下形式:

$$(1 - x_{n,t})p_{n,t} = 0 \quad (3.7)$$

### 3.2.3 离开时对SOC的约束

有迫切充电需求的电动汽车由于连接时间短, 可能无法获得足够的电量, 因此其离开  $SOC_n^{end}$  时的  $SOC$  可能与  $SOC_n^d$  不同。

$$SOC_n^{end} = \min\{SOC_i^C + \frac{p_{n,t} \cdot \Delta t \times \eta_n}{C_n}, SOC_i^d\} \quad (3.8)$$

$$SOC_n^{min} \leq SOC_{n,t} \leq SOC_N^{max} \quad (3.9)$$

其中  $\eta$  表示  $EV n$  充电能量转换效率, 为了延长电池寿命, 建议  $SOC_{min}$  和  $SOC_{max}$  的值分别为15%和90%。

设  $p \triangleq (p_n; n \in \mathcal{N})$  代表电动汽车集群的充电策略。  $EV n$  的可允许充电策略用  $\mathcal{X}_n$  表示, 所有电动汽车可允许充电策略用  $\mathcal{X}$  表示, 为

$$\mathcal{X} \triangleq \mathcal{X}_1 \times \dots \times \mathcal{X}_N \quad (3.10)$$

## 3.3 优化问题

使用  $l_1$  范数逼近  $l_0$  范数。我们将 (3.4) 重新建模为以下稀疏促进充电控制模型

$$\mathcal{J}_1(p) \triangleq \sum_{n \in \mathcal{N}} \left\{ f_n(p_{nt}) + g_n(\sum_{t \in \mathcal{T}} p_{nt}) + \|p_n\|_1 \right\} + \sum_{t \in \mathcal{T}} h_n(\sum_{t \in \mathcal{T}} p_{nt}) \quad (3.11)$$

将集中式电动汽车快速充电协调制定为以下优化问题:

$$\min_{p \in \mathcal{X}} \mathcal{J}_1(p) \quad (3.12)$$

## 4 基于 *Jacobi-Proximal ADMM* 的 电动汽车充电框架

ADMM方法已经成为大规模结构化的有力工具,值得注意的是,ADMM 可以解耦空间耦合约束,并将解耦问题分解为许多个小问题,其中每个子问题分解都很容易解决.在 [1] 中提出了并行分布式计算 *Jacobi-Proximal ADMM*.近端项的灵活使用以不同的方法解决子问题提高了标准 ADMM 的收敛率.*Jacobi-Proximal ADMM* 对于稀疏性问题保持了很好的性质.在每次迭代中,该方法使用软阈值操作来更新变量,这可以促进解在稀疏表示下的稀疏性,即保持或增强变量的稀疏性质,该算法扩展了乘法器交替方向法(ADMM),将原问题分解为N个较小的子问题,并在每次迭代时并行求解.

值得注意的是,在模型 (11) 中的第二项耦合了所有的变量  $p_{n,t}$ ,  $n \in \mathcal{N}$ , 为了解耦此项,引入辅助变量

$$\mathbf{p}_{N+1} = (p_{N+1,1}, \dots, p_{N+1,1})^T \in \mathbb{R}^T$$

其中  $p_{N+1,t} = \sum_{t \in \mathcal{T}} p_{nt} - \Gamma_n$ ,  $t \in \mathcal{T}$ , 因此模型(3.4)等价表示如下:

$$\min_{\mathbf{p}} \mathcal{J}(\mathbf{p}) \quad (4.1)$$

$$s.t. \sum_{n \in \mathcal{M}_t} p_{n,t} \leq c_{lt} \quad (4.2)$$

$$p_{N+1,t} = \sum_{t \in \mathcal{T}} p_{nt} - \bar{\mathbf{p}}, t \in \mathcal{T} \quad (4.3)$$

为了使用 *Jacobi-Proximal ADMM*, 定义

$$\mathbf{P} = \{\mathbf{p}_1, \dots, \mathbf{p}_N, \mathbf{p}_{N+1}\}^T \in \mathcal{R}^{(N+1) \times T} \quad (4.4)$$

也可以写成  $\mathbf{P} = (\mathbf{p}_1, \dots, \mathbf{p}_T) \in \mathbb{R}^{(N+1) \times T}$ , 其中

$$\mathbf{p}_t = (p_{1,t}, \dots, p_{N+1,t}) \in \mathbb{R}^{N+1}, t \in \mathcal{T}. \quad (4.5)$$

定义

$$\mathcal{P}_t^{(2)} = \{\mathbf{p}_t | \mathbf{p}_t \text{ 满足 (4.2) and (4.3)}\} \quad (4.6)$$

且

$$\mathcal{P}_t^{(2)} = \mathcal{P}_1^{(2)} \times \dots \times \mathcal{P}_t^{(2)} \times \dots \times \mathcal{P}_T^{(2)} \quad (4.7)$$

其中约束  $\mathcal{P}_t^{(2)}$  是一个全局约束,在空间上耦合所有EV的充电时间表. $\mathcal{P}_t^{(2)}$  是闭的、非空凸集的指示函数是恰当的.闭的和凸的,所以为了使用 *Jacobi-Proximal ADMM* 更一步介绍以下凸集  $\mathcal{P}^{(i)}$ ,  $i = 1, 2$ , 如下,

$$\mathcal{I}_i(\mathbf{p}) = \begin{cases} 0 & \text{if } \mathbf{p} \in \mathcal{P}^{(i)}, \\ +\infty & \text{otherwise.} \end{cases} \quad (4.8)$$

很清楚地,  $\mathcal{I}_i(\mathbf{p})$ ,  $i = 1, 2$  是凸函数.

很容易地将 (4.1)–(4.3) 所描述的问题写成标准的ADMM 形式, 如下所示

$$\begin{aligned} \min_{\mathbf{P}, \mathbf{Y}} \mathcal{J}(\mathbf{P}) + \mathcal{I}_1(\mathbf{P}) + \mathcal{I}_2(\mathbf{Y}) \\ s.t. \mathbf{P} - \mathbf{Y} = \mathbf{0}. \end{aligned} \quad (4.9)$$

这里定义:

$$F(\mathbf{P}) \triangleq \mathcal{J}(\mathbf{P}) + \mathcal{I}_1(\mathbf{P})$$

$$G(\mathbf{Y}) \triangleq \mathcal{I}_2(\mathbf{Y})$$

定义增广拉格朗日函数如下:

$$\begin{aligned} \mathcal{L}_\rho(\mathbf{P}, \mathbf{Y}, \mathbf{U}) &= F(\mathbf{P}) + G(\mathbf{Y}) + \Lambda^T(\mathbf{P} - \mathbf{Y}) + \frac{\rho}{2} \|\mathbf{P} - \mathbf{Y}\|_F^2 \\ &= f(\mathbf{P}) + g(\mathbf{Y}) + \frac{\rho}{2} \|\mathbf{P} - \mathbf{Y} + \mathbf{U}\|_F^2 \end{aligned} \quad (4.10)$$

其中  $\rho > 0$  是惩罚参数,  $\Lambda$  称为对偶变量或者拉格朗日乘子,  $\mathbf{U}$  称为缩放后的对偶变量, i.e.  $\mathbf{U} = (1/\rho)\Lambda$  变量  $\mathbf{P}, \mathbf{Y}, \mathbf{U}$  的更新

$$\mathbf{P}^{k+1} \triangleq \underset{\mathbf{P}}{\operatorname{argmin}} \left\{ \mathcal{L}_\rho(\mathbf{P}, \mathbf{Y}, \mathbf{U}^k) + \frac{1}{2} \|\mathbf{P} - \mathbf{P}^k\|_\Phi^2 \right\} \quad (4.11)$$

$$\mathbf{Y}^{k+1} \triangleq \underset{\mathbf{Y}}{\operatorname{argmin}} \left\{ \mathcal{L}_\rho(\mathbf{P}^k, \mathbf{Y}, \mathbf{U}^k) + \frac{1}{2} \|\mathbf{Y} - \mathbf{Y}^k\|_\Psi^2 \right\} \quad (4.12)$$

$$\mathbf{U}^{k+1} \triangleq \mathbf{U}^k - \zeta \rho (\mathbf{P}^{k+1} - \mathbf{Y}^{k+1}) \quad (4.13)$$

**Definition 4.1.** 如果选择  $\delta_i > 0$  使得参数  $\rho, \zeta, \Phi, \Psi$  满足以下的情况:

$$\begin{cases} \Phi \succ \rho(\frac{1}{\delta_1} - 1)I, \\ \Psi \succ \rho(\frac{1}{\delta_2} - 1)I, \\ \delta_1 + \delta_2 < 2 - \zeta, \end{cases}$$

选择参数  $\rho, \zeta, \Phi, \Psi$  的方法多种多样, 本文采用一个简单的选择  $\Phi = \phi I, \Psi = \psi I$  使得

$$\begin{cases} \phi \succ \rho(\frac{1}{\delta_1} - 1), \\ \psi \succ \rho(\frac{1}{\delta_2} - 1), \\ \delta_1 + \delta_2 < 2 - \zeta, \end{cases}$$

## 5 计算P

本节给出了在计算  $\mathbf{P}$  的详细信息, 从指示函数的定义中可以容易地看出,  $\mathbf{p}^{k+1}$  的实际优化策略如下:

$$\mathbf{P}^{k+1} = \underset{\mathbf{P} \in \mathcal{P}^{(1)}}{\operatorname{argmin}} \left\{ F(\mathbf{P}) + \frac{\rho}{2} \|\mathbf{P} - \mathbf{Y}^k + \mathbf{U}^k\|_F^2 + \frac{\phi}{2} (\mathbf{P} - \mathbf{P}^k)^T (\mathbf{P} - \mathbf{P}^k) \right\} \quad (5.1)$$

当  $n = N + 1$  时

$$\mathbf{p}_{N+1}^{k+1} = \frac{\rho(\mathbf{U}_n^k - \mathbf{y}_{N+1}^k) + \phi \mathbf{P}_{N+1}^k}{2 + \rho + \phi} \quad (5.2)$$

对于每一个  $n=1, \dots, N$ , 令

$$f(\mathbf{p}) \triangleq \sum_{n \in \mathcal{N}} \left\{ f_n(p_{nt}) - \omega_n g_n \left( \sum_{t \in \mathcal{T}} p_{nt} \right) + \gamma \|\mathbf{p}_n\|_1 \right\}$$

相应的子问题计算如下

$$\mathbf{p}_n^{k+1} = \underset{\mathbf{p}_n \in \mathcal{P}_n^{(1)}}{\operatorname{argmin}} \left\{ f(\mathbf{p}) + \frac{\rho}{2} \|\mathbf{p}_n - \mathbf{y}_n^k + \mathbf{U}_n^k\|_F^2 + \frac{\psi}{2} (\mathbf{p}_n - \mathbf{p}_n^k)^T (\mathbf{p}_n - \mathbf{p}_n^k) \right\} \quad (5.3)$$

## 6 计算Y

(6.7)的对偶问题为

本节详细介绍 (4.12) 中变量  $\mathbf{Y}$  的更新, 等价于求解以下凸优化问题的解:

$$\mathbf{Y}^{k+1} = \underset{\mathbf{Y}}{\operatorname{argmin}} \mathcal{I}_2(\mathbf{Y}) + \frac{\rho}{2} \|\mathbf{P}^k - \mathbf{Y} + \mathbf{U}^k\|_F^2 + \frac{\psi}{2} \|\mathbf{Y} - \mathbf{Y}^k\|_F^2 \quad (6.1)$$

$$\max_{\lambda_t \geq 0, \mu_t} \left\{ D^t(\lambda_t, \mu_t) = \sum_{n=1}^{N+1} \min_{y_t} \mathcal{L}^t(y_t; \lambda_t, \mu_t) \right\} \quad (6.8)$$

根据(6.8), 目标函数被重写为

$$= \underset{\mathbf{Y} \in \mathcal{P}^{(2)}}{\operatorname{argmin}} \frac{\rho}{2} \|\mathbf{Y} - (\mathbf{P}^k + \mathbf{U}^k)\|_F^2 + \frac{\psi}{2} \|\mathbf{Y} - \mathbf{Y}^k\|_F^2$$

对于  $\mathbf{y}$  - update 的更新, 可以由以下分散方式计算变量

$$D^t(\lambda_t, \mu_t) = \sum_{n=1}^{N+1} \min_{y_{n,t}} \mathcal{L}_n^t(y_t; \lambda_t, \mu_t) \quad (6.9)$$

$$\min_{\mathbf{y}_t \in \mathcal{P}_t^{(2)}} \{ (\rho + \psi) \mathbf{y}_t^T \mathbf{y}_t - 2(\rho(\mathbf{p}_t^k + \mathbf{U}_t^k) + \psi \mathbf{y}_t^k) \mathbf{y}_t \} \quad (6.2)$$

第二种思路:

由于(6.1)中的函数是解耦的, 因此计算其变量  $y_t^k$ ,  $t=1, \dots, T$  的优化问题为

$$\min_{y_t \in \mathcal{P}_t^{(2)}} [(\rho + \psi) y_t^2 - 2(\rho(p_i^k + u_i^k) + \psi y_i^k) y_t] \quad (6.10)$$

$$s.t. \quad \hat{p}_{nt}^{min} \leq y_t \leq \hat{p}_{nt}^{max} \quad (6.11)$$

子问题(6.2)是一个CQP问题. 为了简化符号, 我们引入一个  $(L \times N)$  矩阵  $A^t$  来表示时刻  $t$  的馈线用户关联矩阵及其在  $a_{l,n}^t$  处的分量

$$a_{l,n}^t = \begin{cases} 1 & \text{if PEV } n \text{ uses feeder } l \text{ at time } t \\ 0 & \text{otherwise} \end{cases} \quad (6.3)$$

设  $A^t = (a_1^t, \dots, a_N^t)$  是  $A^t$  的第  $n$  列向量, 表示  $EVn$  使用的相应馈线  $a_{N+1}^t = 0 \in \mathcal{R}^L$ ,  $c^t = (c_{1,t}, \dots, c_{l,t})$ ,  $b_n - 1, n \in \mathcal{N}$ ,  $b_{N+1} = 1$ , 那么子问题重写为

它的解析解很容易得:

$$y_t^{k+1} = \begin{cases} \hat{p}_{nt}^{min} & \bar{y}_t^{k+1} < \hat{p}_{nt}^{min} \\ \bar{y}_t^{k+1} & \hat{p}_{nt}^{min} \leq \bar{y}_t^{k+1} \leq \hat{p}_{nt}^{max} \\ \hat{p}_{nt}^{max} & \bar{y}_t^{k+1} > \hat{p}_{nt}^{max} \end{cases} \quad (6.12)$$

$$\min \sum_{n=1}^{N+1} [(\rho + \psi) y_{n,t}^2 - 2(\rho(p_{n,t}^k + U_{n,t}^k) + \psi y_{n,t}^k) y_{n,t}] \quad (6.4)$$

$$s.t. \quad \sum_{n=1}^{N+1} a_n^t y_{n,t} \leq c^t \quad (6.5)$$

$$\sum_{n=1}^{N+1} b_n y_{n,t} = d_t \quad (6.6)$$

引入子问题 (6.4)-(6.6) 的拉格朗日函数

$$\mathcal{L}^t(\mathbf{y}_t; \lambda_t, \mu_t) = \sum_{n=1}^{N+1} [(\rho + \psi) y_{n,t}^2 - 2(\rho(p_{n,t}^k + U_{n,t}^k) + \psi y_{n,t}^k) y_{n,t}] \quad (6.7)$$

$$+ \lambda_t^T [a_n^t y_{n,t} - c^t / (N+1)] + \mu_t [b_n y_{n,t} - d_t / (N+1)]$$

$$:= \sum_{n=1}^{N+1} \mathcal{L}_{n=1}^t(y_t; \lambda_t, \mu_t)$$

$$\mathbf{r}^k = \|\mathbf{P}^k - \mathbf{Y}^k\|_F$$

$$\mathbf{s}^k = \|\rho(\mathbf{Y}^{k+1} - \mathbf{Y}^k)\|_F$$

## 7 算法

算法收敛的表证如下:

$$\|\mathbf{r}\|_2 \leq \varepsilon^{pri} \quad \|\mathbf{s}\|_2 \leq \varepsilon^{dual} \quad (7.1)$$

**Definition 7.1.** 如果选择  $\delta_i > 0$  使得参数  $\rho, \zeta, \Phi, \Psi$  满足以下的情况:

$$\begin{cases} \Phi \succ \rho(\frac{1}{\delta_1} - 1)I, \\ \Psi \succ \rho(\frac{1}{\delta_2} - 1)I, \\ \delta_1 + \delta_2 < 2 - \zeta, \end{cases}$$

选择参数  $\rho, \zeta, \Phi, \Psi$  的方法多种多样, 本文采用一个简单的选择  $\Phi = \phi I, \Psi = \psi I$  使得

$$\begin{cases} \phi \succ \rho(\frac{1}{\delta_1} - 1), \\ \psi \succ \rho(\frac{1}{\delta_2} - 1), \\ \delta_1 + \delta_2 < 2 - \zeta, \end{cases}$$

**Theorem 7.2.** aaaa

算法收敛的表证如下:

$$\mathbf{r}^{k+1} = \|\mathbf{P}^{k+1} - \mathbf{Y}^{k+1}\|_F$$

$$\mathbf{s}^{k+1} = \|\rho(\mathbf{Y}^{k+1} - \mathbf{Y}^k)\|_F$$

一个合理的终止标准是原始残差和对偶残差要足够小, 如下:

$$\|\mathbf{r}^k\|_2 \leq \varepsilon^{pri} \quad \|\mathbf{s}^k\|_2 \leq \varepsilon^{dual}$$

where  $\varepsilon^{pri} > 0$  和  $\varepsilon^{dual} > 0$  are feasibility tolerances for the primal and dual feasibility condition-

---

**Algorithm 1** Jacobi-Proximal ADMM

---

**Input:**  $\mathbf{p}_n^0 (n = 1, \dots, N + 1), \Lambda^0$ **Output:**  $\mathbf{p}_n^k (n = 1, \dots, N + 1)$ 

```
1: for  $k=0,1,\dots$  do
2:   Update  $\mathbf{p}_n$  for  $n = 1, \dots, N + 1$  in parallel by:
3:    $\mathbf{p}_n^{k+1} = \text{argmin} \left\{ f_n(\mathbf{p}_n) + \frac{\rho}{2} \|A_n \mathbf{p}_n + \sum_{j \neq n} A_j \mathbf{p}_j^k - c - \frac{\Lambda^k}{\rho}\|_2^2 + \frac{1}{2} \|\mathbf{p}_n - \mathbf{p}_n^k\|_\Psi^2 \right\}$ 
4:   Update  $\Lambda$  by:
5:    $\Lambda^{k+1} = \Lambda^k - \gamma \rho (\sum_{n=1}^N A_n \mathbf{p}_n^{k+1} - c)$ 
6:   if  $\sum_{n=1}^{N+1} \|\mathbf{p}_n^{k+1} - \mathbf{p}_n^k\|_F \leq \varepsilon^{pri}$  then
7:     Break.
8:   end if
9: end for
```

---

s () and (). These tolerances can be chosen using an absolute and relative criterion, such as

$$\begin{aligned} \varepsilon^{pri} &= \sqrt{N} \varepsilon^{abs} + \varepsilon^{rel} \max\{\|p\|_2, \|x\|_2\}, \\ \varepsilon^{dual} &= \sqrt{N} \varepsilon^{abs} + \varepsilon^{rel} \|\mu^k\|_2 \end{aligned}$$

where  $\varepsilon^{abs} > 0$  is an absolute tolerance and  $\varepsilon^{rel} > 0$  is a relative tolerance. A rea-

sonable value for the relative stopping criterion might be  $10^{-3}$  or  $10^{-4}$ . A pseudo-code for the proposed Prox-JADMM is then given in Algorithm 1.

**Theorem 7.3.** *aaaa*

## 8 实验结果